基于工具调用与证据追踪的财报分析系统设计与实现

作者姓名待填写　单位待填写

工程论文初稿　2026 年 10 月 3 日　三轮冻结评测归档

摘要

针对财报问答中金额口径混淆、来源难以定位及分析代码缺少隔离的问题，本文实现单机财报分析系统。单一 Pi 智能体组织任务，Python MCP 服务负责解析、检索、查询与十进制计算，SQLite 保存事实和证据，独立 Docker 容器执行科学计算。自建回归集含三份中文年报及 FinQA 抽样，共 186 题；公开标签经先读材料、独立求解、再比较旧答案的代理复核后冻结。官方 deepseek-flash 在 124 题验收集上完成三轮，答案正确率为 83.06%—87.90%，答案及证据联合正确率为 66.94%—69.35%，结论一致率 90.32%，未达到全部预设门槛。历史确定性解析对同 30 个事实重复三轮通过 90/90，独立真实年报制图演示的 6 个金额核对一致，两者均不替代模型评测。结果表明工程链路能够运行，但歧义拒答、证据格式和稳定性仍有不足；标签集合覆盖及公开规范的解释冲突亦限制评分结论。

关键词：财报分析；工具调用；证据追踪；MCP；结构化查询；隔离执行

1 引言

年度财务报告同时包含正文、会计报表、附注、比较期数据及审计意见。读者提出“利润增长是否得到现金流支持”时，需要先定位正确公司的年度数据，区分归母利润与净利润，统一金额单位，再完成计算并解释结果。自然语言生成只是工作链条的最后一环。如果系统把原始财报一次性塞入模型上下文，用户通常只能看到一个看似完整的结论，难以确认数字来自哪一页、采用何种口径，也难以复查算术过程。

财报场景中的小错误可能形成数量级差异。以本项目处理的公开资料为例，同为主要会计数据表，一份报告直接以元披露，另一份使用千元。两个原始字符串虽然都能被识别为数值，却不能在未经换算的情况下比较。跨页表格还会出现表头与数据分离、空列数量改变、印刷页码与 PDF 物理页码不同等问题。只检查回答是否流畅或是否包含引用标记，不能覆盖这些失效方式。

本文的目标是实现一套可以上传文件、查询数值、执行分析、追溯证据并保留运行记录的应用。系统贡献主要体现在三个方面：把模型负责的任务组织与程序负责的数据处理分开；在事实、计算和原始位置之间保留可检查的关联；通过分层实验防止把局部测试通过误认为整体能力已经成立。本文不提出新的基础模型或训练算法，也不把自建回归集成绩表述为比赛官方评测或通用金融推理性能。

2 相关工作

FinQA 面向财务材料中的数值推理，为问题提供文本、表格与可执行推理程序，强调金融问答不仅需要检索，还需要多步计算[1]。本文借鉴其可执行答案核验思路，从官方公开数据中抽取独立算术任务，作为英文补充层。由于本项目只选取其中的子集，题型分布和数据划分与官方完整实验不同，后续得分不能直接与论文中的完整 FinQA 结果比较。

检索增强生成将外部文档检索与语言生成连接，使答案能够使用可更新的非参数化信息[2]。财报系统还需要另一条精确查询通路：相关段落可以通过文本或向量匹配获得，但计算用的金额应从经过单位与期间校验的事实记录读取。因此，本文把证据检索与财务事实查询做成两个独立工具，并要求生成结果保留相应来源。

ReAct 研究了语言模型在任务执行中交替进行推理与外部动作的方式[3]。本文使用工具调用组织检索、查询与计算，但只向用户显示可观察的动作、工具结果和依据，不把模型内部思考过程当作审计证据。MCP 提供宿主、客户端和服务端之间的标准接口[4]；Pi SDK 则允许宿主应用嵌入会话、模型、资源和工具控制[5]。这些基础设施提供集成能力，项目权限校验和财务语义仍须由应用自行实现。

3 问题定义与设计要求

3.1 输入输出与事实模型

设输入文档集合为 D，用户问题为 q，项目标识为 p。系统的输出不仅是回答 a，还包括证据集合 E、计算记录 C 和产物集合 A。每个财务事实以公司、指标、期间、币种、会计口径、数值及来源位置表示。来源位置至少包含文档标识和物理页；对结构化表格还记录工作表、表标识、行列与单元格。相同数值在不同口径或来源版本下仍是不同事实，不能仅按指标名称覆盖。

流量指标使用年度期间，资产和权益等存量指标使用期末日期。营业收入、归母净利润和经营活动现金流量净额属于年度流量；总资产与归母净资产属于期末存量。用户上传的自定义表格如果没有说明币种、单位或合并口径，系统应显示信息不足或未指定口径，而不是填入一个方便计算的默认值。对同一事实键出现的冲突值，保存替代来源并返回复核提示。

3.2 可验证性和运行边界

可验证性要求用户能够从回答跳转到原始证据，并检查派生指标的输入和公式。固定公式不交给语言模型心算：同比增长率定义为本期与上期之差除以上期，再乘以 100；基期为零时返回无法计算，不生成无穷大或任意百分比。金额以十进制字符串保存，计算使用 Decimal，避免二进制浮点误差在金额比较中传播。

运行边界要求模型只能访问当前项目授权的数据和工具。上传接口接收文件后生成内部标识，文件路径由宿主控制；模型不获得任意 SQL、全盘读取或 shell 能力。自定义分析代码可以使用科学计算库，但不能因此继承模型密钥、数据库文件或容器管理权限。本项目以个人竞赛和研究环境为部署目标，不声称能完全抵御恶意多租户场景中的内核级攻击。

4 系统架构与实现

4.1 单智能体与模块划分

系统由 React 与 TypeScript 前端、Node 应用控制层、嵌入式 Pi 会话、Python 金融 MCP 服务、SQLite 数据层及分析容器组成。Pi 负责理解请求、选择工具和组织报告。解析器、检索器、固定公式计算与存储均作为确定性模块实现，没有为每个模块再创建一个智能体。当前任务的控制流主要是上传、解析、查询、分析和输出，单会话工具循环能够表达这一过程，暂不额外引入复杂状态图框架。



图 1 系统组件及数据流

Node 控制层处理项目、会话、上传、配置、SSE 事件与取消请求，并把项目标识绑定到工具调用。Pi 会话显式设置业务工具集合和资源加载方式，使默认开发工具不会随运行环境自动进入财务任务。服务端再次检查项目、文档和任务的所属关系；宿主绑定与服务校验共同形成边界，不能只依赖提示词要求模型“不要读取其他项目”。

本系统选用 DeepSeek 官方 DeepSeek-V4.1-Flash，API 标识为 deepseek-flash，服务地址为 https://api.deepseek.com，支持工具调用与思考模式[11]。模型名称依据官方文档和实际模型列表核验，密钥由 Node 加密保存并在运行时注入，不进入文档、数据库事实或分析容器。模型承担任务组织和文字解释，精确数字仍必须来自项目内的查询与计算工具。

表 1 核心组件与职责

组件	承担的工作	重要约束
对话前端	附件、消息、配置、证据与下载	不直接向模型供应商发送密钥
Node 与 Pi	会话组织、工具白名单、任务事件	宿主绑定 project_id
Python MCP	解析、查表、检索、固定计算	不开放任意 SQL 和主机路径
SQLite 与文件目录	事实、索引、原文、任务状态	项目隔离及内容哈希
分析容器	科学计算与图表产物	输入只读、断网、资源受限

4.2 文件解析与口径标准化

PDF 使用文本及几何信息抽取页面内容和表格，保存物理页与可识别的印刷页码。表格定位结果与全文片段分别入库。文本明显不足的页面或独立上传的图片转入 OCR 流程，保存识别框及置信信息，结果标记为需要复核。图片任务只使用上传图片，不因为文件名看起来对应某份年报就读取原 PDF，这一点对图像读表实验的有效性尤其重要。

Excel 直接读取工作表、单元格值、公式与已有缓存值；CSV 和 TSV 读取编码、分隔符及原始行列。含公式但缺少缓存值的单元格不被当作零，也不会在宿主机启动办公软件执行未知宏。标准化模块识别常见指标别名，处理千分位、括号负数、缺失标记与金额单位，并保留原字符串和规范值。无法明确识别的字段仍保存在原表中供检索，但不自动成为可计算事实。

跨页表格是实现中的一个实际故障点。解析器可能在一页插入多个空列，下一页却返回更少的列。直接复制上一页的列号，会让年份与同比列错位。本系统要求下一页的开头出现可识别财务指标，再根据表头与数据列的物理中心位置承接年份。OCR 表格也按年份文字的图像坐标对齐数值列，避免左上角没有指标标题时整体偏移；百分比文本不能作为金额入库。 parser 0.1.2 另检查季度、月份和半年度表头；出现新的非年度期间时停止继承上一表的年度列映射，并保留原表供查阅。当前事实规范只覆盖年度，不能把季度金额强行标为全年。

事实查询优先采用主要会计数据等来源，但不会把不同公司、期间、币种或口径合并成一条记录。合并报表与母公司报表分别返回；接口允许显式筛选口径。遇到相同优先级而数值不同的候选记录，返回冲突提示和替代来源。规则覆盖范围是常见年度财务表格，不能等同于已经理解所有附注、会计重述和复杂财务报告版式。

4.3 存储与证据检索

SQLite 保存项目、文档、页面、表格、财务事实、文本片段、向量缓存与应用状态。数据库启用 WAL、外键和锁等待超时，由 Python 服务统一执行写入；Node 通过宿主专用工具保存对话与运行状态。WAL 改善读写并行，但不能消除所有写锁竞争，仍需控制事务长度[6]。原始文件与较大的图像、分析产物保存在目录中，数据库记录相对路径和哈希。

文档幂等键由项目、文件内容哈希和解析器版本构成。相同内容再次上传时复用已有文档与任务，不重复写入事实。解析阶段采用 queued、parsing、validating、ready、needs_review、failed 和 cancelled 状态；异常中断后的任务不能继续显示成功。服务重启时将未完成的解析标为失败，允许重新提交恢复，避免在界面上长期停留于不真实的进度。

检索分为词项匹配和可选向量匹配。FTS5 对中文构造重叠二元词，对拉丁文本使用词项；Embedding 由服务端调用单独配置的接口，缓存键包含项目、接口、模型、维度与文本哈希。上传解析完成、配置变化及检索时自动调度后台索引，配置变更使用新的缓存命名空间，避免错用其他模型的向量。检索遵守项目和公司等过滤条件，再融合可用排名。索引不完整或接口失败时，工具返回词项结果、索引状态与明确警告；精确财务问题直接查询规范化事实表。

4.4 计算工具与隔离分析

固定公式工具支持同比、比值、利润率、现金转化率与基本算术，输入可以引用当前项目的事实标识。工具输出公式、原始输入、十进制结果、单位和来源集合。只有需要自由统计、定制图表或较复杂处理时，才把代码交给分析运行器。此分工使常见计算易于检查，也让动态代码的执行范围保持清晰。

运行器在每个任务开始前导出当前项目的表格与事实副本，不把数据库、完整工作区或标准答案目录挂入容器。容器使用非 root 用户、只读根文件系统、断网、禁用额外能力和 no-new-privileges，并限制 CPU、内存、进程数、运行时间及输出体积。Docker 默认并不会自动为所有容器设置所需资源上限，限制必须由启动参数明确指定[7]。启动权限只在可信宿主侧持有。

产物回收需要验证文件类型、大小、路径、普通文件属性及内容哈希，拒绝符号链接或路径越界。分析环境预装 NumPy、pandas、SciPy、Matplotlib、Seaborn、statsmodels、scikit-learn、openpyxl 和中文字体，运行时不联网安装包。Windows 上可通过项目管理的 Linux 虚拟机承载 Docker，仍在容器中执行分析；容器不可用时明确失败，不降级为宿主 Python 执行。

4.5 对话界面与配置

界面采用黑白灰的桌面对话布局。用户在中央输入任务，通过输入框旁的附件入口上传表格或财报，也可拖拽文件。上传后展示真实解析状态；进入对话后输入框固定在下方。文件与证据面板默认收起，点击附件、引用或来源位置才展开。这样，入口始终围绕用户任务，而不是要求用户先理解数据库和工具架构。

主模型、Embedding、OCR 和运行限制分别配置。模型名称与接口地址属于非秘密配置；密钥由应用后端保管，前端读取时脱敏，金融服务只在内存中保留需要的凭据。界面提供新对话、取消、历史会话、文件预览和产物下载。状态文本区分本地预览、后端解析与真实模型执行，防止演示回复或测试夹具被误认为模型已经完成分析。

5 实验设计

5.1 数据集与划分

中文资料采用贵州茅台、美的集团和伊利股份的 2024 年完整年度报告，共 143、295 和 270 个 PDF 物理页，合计 708 页[8—10]。2023 年比较值来自相应 2024 年报告中的比较列，并非另外三份 2023 年完整年报。中文开发组使用茅台，验收组使用美的和伊利。三份报告都经过解析层开发与回归检查，因此该划分用于冻结后的工程验收，不能称为完全未见材料的盲测。

自建回归集共 186 题，开发集 62 题，验收集 124 题。中文层包含字段提取、固定计算、真假陈述核查、证据不足和图像读表；英文层从 FinQA 官方公开 dev 与 test 材料确定性抽样 120 道算术题，单步与多步各 60 道。抽样程序、上游版本、许可与文件哈希均保留，原始 FinQA 中的答案不作为被测智能体输入。

表 2 回归集题型与划分

题型	开发	验收	合计
中文字段提取	10	20	30
中文财务计算	4	8	12
真假陈述核查	4	8	12
证据不足	2	4	6
图像读表	2	4	6
FinQA 单步	20	40	60
FinQA 多步	20	40	60
合计	62	124	186

5.2 输入隔离与评分协议

每道模型评测题只导出允许的材料，并使用独立项目、会话和缓存。标准答案、参考数据库及含答案的上游原文件位于评分侧，不能挂载到模型任务环境；OCR 题只提供图片。模型接收问题、材料和公开的输出单位约定，返回十进制数值、单位、期间、口径与引用。证据不足必须给出对应状态和原因。对未明确要求百分比或比值的增加额问题，协议采用绝对变化；单题的正确答案、歧义标签和复核记录不进入模型输入。

v0.1 直接使用公开 FinQA 执行标签。开发检查发现其中存在公式、年份与数量级错误，也有材料不能唯一确定目标的问题。v0.2 保留全部 186 题和原材料；120 道 FinQA 由分工代理先独立阅读题目与允许材料、保存算式和材料哈希，再与旧标签比较。复核得到 80 题核对一致、20 题纠正、20 题有歧义。这是独立代理复核，不是人工双标。歧义题不删除，要求返回证据不足并引用歧义依据；旧标签及旧评分单独保留，不用模型预测反向生成答案。

中文金额容差为 0.01 元，同比为 0.005 个百分点，比值为 0.00005；FinQA v0.2 依据逐题 Decimal 结果和显式绝对容差核验，保留披露精度合理的舍入变体。漏答、失败和超时计入分母。来源评分允许一组或多组独立充分证据：直接披露变化额的段落，与两个年度数值所在行，可以构成替代证据集；不要求模型同时引用所有重复位置。表头等有效背景证据单独记录。答案及证据联合正确率要求数值或拒答状态正确，并覆盖至少一组充分证据；引用命中仍不等于开放式论证质量。

评分器另完成 32 项方法测试，标准答案回代自检覆盖 186 题和 218 组充分证据，检查公开输入中不含隐藏标签。这是评分程序一致性检查，不产生模型成绩，也不能单独证明复核标签没有语义错误。

数据门槛和运行门槛单独列出。系统验收检查科学计算库与中文绘图、输入只读、网络隔离、凭据和文件隔离、超时取消、资源上限、产物边界、项目隔离、提示注入、绘图数值、中断幂等及重复运行审计。任何一个数据准确率都不能替代这些边界检查。对于只有几道题的类别，还须报告样本数量，避免百分比给读者造成过度精确的印象。

6 实验结果与分析

6.1 确定性解析与查询层

为验证解析和数据库查询的实际链路，实验从三份原始 PDF 创建全新数据目录，每份报告使用独立项目，查询营业收入、归母净利润、经营活动现金流量净额、总资产和归母净资产在 2023 与 2024 两个期间的数值，每轮得到 30 条预测。整个过程重复三次。预测驱动程序不读取标准答案；预测文件落盘后，由独立宿主评分程序与中文提取题标准进行对照。

历史 parser 0.1.1 实验中，三轮均实际提取并持久化 708 页内容，30 个目标值的数值、期间、口径和引用每轮全部通过，共 90/90，各轮数值及页码一致。总耗时 384.203 秒，平均每轮 128.068 秒。这是同 30 个事实的重复查询，不是 90 个独立未知样本，也不是语言模型成绩。实验代码哈希按原记录保留；后续 parser 0.1.2 包含新修复，不能把历史结果改标为新版本的重新测试。

表 3 三轮原始财报解析与查询结果

轮次	物理页	目标事实	数值及引用通过	耗时 秒
1	708	30	30/30	121.938
2	708	30	30/30	118.750
3	708	30	30/30	143.515

真实材料还暴露年度表头跨页继承到季度表的错误：伊利原报告第 8 物理页第二季度金额一度被标为 2023 全年。parser 0.1.2 遇明确非年度表头时中止年度事实提取，并以合成表、伊利原页和真正年度延续表回归。原文与表格仍可查；此修复证明具体失效方式得到约束，不能证明所有季度、重述及附注口径已经支持。

6.2 接口与交互验证

冻结前金融服务 21 项自动检查全部通过，覆盖 MCP 调用、CSV 和 Excel 解析、十进制单位、未知单位、幂等、上传路径和项目边界、FinQA 来源标识、异步分析状态与时限，以及年度与季度表头边界。Embedding 自动索引、配置变更重建及失败回退使用本地协议夹具核验。正式模型评测未启用 Embedding，实际使用词项检索；这些测试不证明外部向量模型的语义质量。

Pi 与 MCP 集成测试实际连接两者，使用模型协议桩检查工具循环及事件，不能衡量模型能力。前端另有 14 项固定 API 响应检查、9 项真实上传和解析 API 检查。官方 deepseek-flash 贯通浏览器、Node/Pi 和 Python 的真实测试通过 9 项，一次任务记录 6 次模型调用、9 次工具调用、耗时 13.432 秒，覆盖 Excel 上传、对话、SSE、证据及持久化。输入为合成开发夹具，不属于回归集成绩。

表 4 不同验证层的证据与含义

验证层	已有证据	能够支持的结论
历史解析与查询	parser 0.1.1 三轮 90/90	同 30 个事实重复重建，非模型成绩
金融服务	21 项自动测试通过	列出的接口与边界行为符合预期
Pi 与 MCP	真实集成加模型协议桩	工具循环与事件管线可协作
前端	14 项夹具、9 项 API、9 项真实模型交互	已覆盖交互入口能够使用
真实模型问答	v0.2 开发 62 题及验收 124 题三轮	完整运行，未达到全部数据门槛
运行与边界	10 项通过、S10 部分、S12 失败	分项证据不等于整体验收通过

6.3 隔离运行与故障恢复

自由分析运行于本机 Linux 虚拟机内的真实 Docker，环境为 QEMU 10.2.0 与 WHPX 加速、Alpine 3.22、Linux 6.12.81、Docker 28.3.3，镜像以 SHA-256 标识固化。S01 至 S07 的依赖、隔离及资源探针通过。120 秒无限循环在 120.221 秒终止；取消探针的容器执行时间为 0.559 秒，不能解释为取消延迟。独立内存上限探针触发 OOMKilled，进程上限 64，超 50 MiB 及符号链接产物被拒绝；Linux 宿主 11 项边界单测通过。该 OOM 探针与 PDF 并发解析故障是不同实验。

S10 使用服务导出的三家公司两年营业收入，真实容器生成图表数据后由宿主独立核对，6 个值一致；3 张中文图仅完成 Codex 代理视觉检查。原规范要求人工视觉核验，实际未执行，因此最终汇总将 S10 标为部分完成，不能沿用早期容器探针的 PASS 字样宣称该项完全满足。该实验是确定性导出到制图的链路，不是模型推理成绩。

合成 CSV 开发探针已贯通真实模型、容器和 HTTP 下载，模型在代码失败后自主修正，PNG 与 JSON 产出及两个金额核对通过。随后另开展三份完整真实年报的应用演示，使用完整文档而非仅提供预选题目页。两类输入分别保存证据，不能把合成数据探针当作真实财报成绩。

正式评测后另以 parser 0.1.2 重新上传三份完整年报，官方 deepseek-flash 经 Pi 自主查询 2023 与 2024 年合并营业收入、核查来源并调用容器制图，使用 11 次模型调用，应用任务耗时 156.062 秒。产物生成后，宿主独立对照参考数据，6/6 个人民币元原值精确一致；绘图用亿元值保留 4 位小数，柱顶标签保留 1 位小数，不能称绘图显示全精度。中文、零基线及柱值经 Codex 代理视觉检查，未执行人工复核。参考库仅用于事后核对。此前演示保留为历史版本；两次单独演示均不计入 186 题成绩，也不改变 S10 人工检查缺失和整体验收未达标的结论。

项目隔离与恢复分别保留应用层和运行器证据。S08 中，跨项目文档、页面、表格、查询和财务计算的 9 个请求均被服务拒绝；容器运行、产物读取与取消也拒绝跨项目访问并留下审计记录。S11 实际终止解析进程后重新启动，任务能够从失败状态重新提交，143 页报告完成解析且未重复入库；另以 SIGKILL 终止宿主运行器验证容器任务的恢复处理。S09 使用真实 DeepSeek 读到含恶意指令的文档文本，任务完成，实际调用仍限制在白名单且项目由宿主绑定。单个注入探针通过仅支持这一场景，不意味着抵御所有提示注入。

6.4 开发基线与冻结评测

v0.1 开发运行收到 62/62 份输出，答案及证据联合正确 20/62（32.26%），三并发墙钟耗时 559.358 秒，共 245 次模型调用。输出覆盖不等于答对。该次运行采用旧 FinQA 标签，并记录运行期间有并发代码变化，因此只保留为开发失败基线，不属于冻结验收，也不能用于判定后续修订标签下的财务正确性。

开发记录暴露了两类实现问题：部分回答未按结构化协议输出；页面与表格工具未把原始 text_N、table_N 标识完整传回，导致可读证据与评分来源无法稳定对应。后续补回有序段落及逐行来源，并统一输出契约。这些修正改变了代码与提示，必须以新的冻结记录重新评测；旧分数与 v0.2 分数还涉及标签和评分协议变化，不能把两者之差全解释为模型能力提升。

v0.2 包含开发集 1 轮与验收集 3 轮真实 deepseek-flash 评测，二者分列报告。开发集答案 58/62、答案及证据 54/62，达到其题型门槛；该开发分数不能替代正式 124 题表现。导入记录的运行期间代码与数据哈希均保持不变。满足完整冻结报告条件的验收运行共 3 轮。至少一项预设数据门槛未通过。各轮具体结果见表 5；单次真实年报演示及旧版开发基线另行列示。

表 5 v0.2 真实模型评测汇总

运行	题数	答案正确	答案及证据正确
开发 第 1 轮	62	58/62 93.55%	54/62 87.10%
验收 第 1 轮	124	104/124 83.87%	86/124 69.35%
验收 第 2 轮	124	109/124 87.90%	83/124 66.94%
验收 第 3 轮	124	103/124 83.06%	84/124 67.74%

表 6 v0.2 分题型结果（正式验收各轮范围）

题型	每轮题数	答案正确率	联合正确率
中文提取	20	100.00%	90.00%—100.00%
中文计算	8	100.00%	75.00%—100.00%
陈述核查	8	100.00%	100.00%
证据不足	4	100.00%	100.00%
图像读表	4	75.00%—100.00%	50.00%—100.00%
FinQA 单步	40	75.00%—80.00%	45.00%—50.00%
FinQA 多步	40	72.50%—82.50%	57.50%—62.50%

正式三轮共 372 次题目执行，仍是同一 124 题的重复测量；四并发累计墙钟时间 2407.021 秒，模型调用 1,503 次，输入 14,781,086 与输出 424,694 个 token。引用召回率为 84.50%—86.04%，定位集合精确率为 91.81%—92.54%。未据 token 用量推算费用。三轮 FinQA 单步均未达到 85%答案门

槛；首轮图像题未达到 90%，第三轮多步题未达到 75%。中文非图像四类的答案均正确，但部分引用仍失分。

按冻结容差比较每对轮次的有效数值或拒答结论，112/124 题三轮一致（90.32%），低于 95%门槛。引用集合完全一致为 64/124（51.61%），主要输出字段完全一致为 36/124（29.03%）。一致性独立于正确性，相同错误也可能一致；失败结果不按有效数值结论计为一致。故代码与数据哈希稳定仍不足以证明回答稳定。

冻结后只读分析首轮：124 份预测中 123 个任务完成、1 个未产生有效最终模型结果。联合失分 38 题，其中 20 题答案契约失败，18 题仅引用失败。前者包括 13 题在冻结政策要求歧义拒答时给标量，2 题已拒答但原因码不符，1 题无有效结果，1 题混淆总负债与影响税率子集，1 题符号约定差异，1 题单位枚举错误，1 题把正确年度利润金额标为期末时点。后者包括 11 题缺年表头、单位或区间边界，4 题 FinQA 定位多加页码，1 题把图片第 1 页当成报告第 7 页，2 题额外引用未登记上下文。因此不能把全部失分归为心算或 OCR 识别错误。该分类仅覆盖首轮，未改标签、代码或原分数。

引用分数仅核验预登记位置，不能等同于逐条语义相关性的人工裁决。首轮美的跨页表头及 FinQA prospective method 介绍均是合理上下文，却因未列入有效集合被扣分。另有一题询问亏损下降，公开约定称下降幅度非负并解释方向，冻结标签却要求负值；模型给正幅度并说明亏损实际扩大。该例存在公开规则与标签的解释冲突，不宜称算术错误。原评分保留，这些限制不被用来事后提高成绩。

选定模型报告：agent-2026-10-03T05-59-01-524Z，模型 deepseek-flash，提示哈希 261c1051a480，代码哈希 93d368e523fe；agent-2026-10-03T06-37-06-859Z，模型 deepseek-flash，提示哈希 261c1051a480，代码哈希 8c9accefb4f3。完整哈希见论文证据导入清单。

独立系统验收报告记录 10/12 项工程条件通过；S10 原值核对与代理视觉检查通过，规定的人工视觉检查未执行，故标为部分完成；S12 重复结论一致性未达标。运行门槛尚未满足，数据门槛尚未满足，完整系统验收尚未满足。当前成果是可运行且完成评测的工程初版，尚未满足全部预设验收条件。

另外保留 1 次未完成的 v0.2 验收尝试及其已有记录。其中美的完整 295 页报告的 20 次全新入库有 6 次触发 ResizeImgError，均发生在模型工具调用之前。底层原因未完全复现，不能确证为内存不足。parser 0.1.2 限制 OCR 线程、串行共享识别器并提前释放页面图像；随后两轮各 4 个并发完整入库全部完成，逐页文本与逐表内容与原成功解析一致。中止记录不计为完成轮次，也不从其中的成功样本推算整集准确率。本文正式三轮采用修复后重新冻结的版本，历史记录保留。

7 局限与后续工作

第一，数据规模和标注独立性有限。三份中文年报均参与过解析开发与回归，不代表对未知版式的泛化。公开 FinQA 也可能进入模型预训练语料，公司划分与运行隔离无法消除预训练污染。v0.2 的复核由代理分工进行，保存先解后比记录及哈希，但不是人工双标，更不是权威重新标注；

仍可能存在共享偏差和遗漏。标签纠正与系统优化发生在开发阶段，正式成绩必须绑定后续冻结版本。

第二，当前字段规范化依赖保守规则。复杂合并单元格、仅标注本期与上期的表格、重述数据、外币换算、分部披露及跨多页附注仍可能需要人工确认。OCR 置信分数也不应被直接解释为财务数值正确概率。系统保留原值、来源和需复核状态，是为了让错误能够被定位，并不意味着自动解析可以替代人工审阅。

第三，系统边界需要持续验证。没有把数据库与密钥挂入容器能够减少暴露面，但容器共享内核，资源耗尽、文件格式漏洞和依赖供应链仍需独立治理。本文的部署目标是个人研究与竞赛应用；用于多人生产服务时，还需要身份认证、权限管理、审计留存、备份恢复及独立安全评估。对任意自定义代码开放更强能力前，必须重新审视威胁模型。

第四，开放式研究质量不在数值评分覆盖范围。正确算出收入和利润，不代表行业比较、因果解释或风险判断成立。官方 API 也可能更新模型权重，记录模型名和代码哈希无法保证远端权重不变。后续需要未见公司与年份、噪声扫描件、口径冲突、人工盲评及检索方案消融，分别测量正确性、引用、时延和调用用量。

8 结论

本文实现了一套以工具调用和证据追踪为核心的财报分析应用。单一智能体负责组织研究任务，确定性模块负责解析、规范化、查询与计算，隔离容器承接自由分析，对话界面把上传、配置和来源复查放在同一工作流程中。三轮原始财报实验表明，选定的主要财务数据能够在新数据库中稳定重建，并保持数值、期间、口径与页码一致。

冻结后的 124 题三轮真实模型评测已完成，但数据门槛、95%的结论一致性门槛及全部系统条件尚未满足。当前版本适合作为可运行、可追溯的工程初版，不能据此声称财报分析已经可靠自动化。后续应优先改进歧义处理、期间单位和引用契约，并在新的独立材料与人工复核下检验；本次冻结标签、失败记录和分数原样保留，不通过事后调参或挑选成功轮次改变结论。

参考文献

[1] CHEN Z, CHEN W, SMILEY C, et al. FinQA A Dataset of Numerical Reasoning over Financial Data. Proceedings of EMNLP, 2021: 3697–3711. DOI 10.18653/v1/2021.emnlp-main.300. https://aclanthology.org/2021.emnlp-main.300/

[2] LEWIS P, PEREZ E, PIKTUS A, et al. Retrieval Augmented Generation for Knowledge Intensive NLP Tasks. NeurIPS, 2020. https://arxiv.org/abs/2005.11401

[3] YAO S, ZHAO J, YU D, et al. ReAct Synergizing Reasoning and Acting in Language Models. ICLR, 2023. https://arxiv.org/abs/2210.03629

[4] Model Context Protocol. Architecture Specification 2025 11 25.

https://modelcontextprotocol.io/specification/2025-11-25/architecture （访问日期 2026 年 10 月 3 日）

[5] Earendil Works. Pi SDK Documentation. https://github.com/earendil-works/pi/blob/main/packages/coding-agent/docs/sdk.md （访问日期 2026 年 10 月 3 日；项目依赖固定版本 1.0.0）

[6] SQLite. Write Ahead Logging. https://www.sqlite.org/wal.html （访问日期 2026 年 10 月 3 日）

[7] Docker. Resource Constraints. https://docs.docker.com/engine/containers/resource_constraints/ （访问日期 2026 年 10 月 3 日）

[8] 贵州茅台酒股份有限公司. 2024 年年度报告. 巨潮资讯公开披露文件, 2025. https://static.cninfo.com.cn/finalpage/2025-04-03/1222993920.PDF

[9] 美的集团股份有限公司. 2024 年年度报告. 公司投资者关系官网, 2025. 来源 URL 及内容 SHA256 见 benchmark/sources/manifest.json.

[10] 内蒙古伊利实业集团股份有限公司. 2024 年年度报告. 巨潮资讯公开披露文件, 2025. https://static.cninfo.com.cn/finalpage/2025-04-30/1223421123.PDF

[11] DeepSeek. 模型与价格；Models API. https://api-docs.deepseek.com/zh-cn/quick_start/pricing/ ; https://api-docs.deepseek.com/api/list-models/ （访问日期 2026 年 10 月 3 日；实际 API 标识 deepseek-flash）