Finance Agent：证据驱动的财报研究智能体

2026 年北京市大学生金融人工智能竞赛 · 初赛项目计划书

参赛方向	② 上市公司财务报告分析（兼顾 ① 数据结构化提取、④ 自动化估值建模）
队伍名称	【队伍】
成员 / 指导教师	【队伍】
联系方式	【队伍】
作品形态	本机运行的 Web 研究工作台（Windows x64 便携包），附完整源码、运行说明与评测证据

一、项目概述

一句话：Finance Agent 让大模型像一位严谨的研究员那样读财报——每个数字都能回到原文页码，每一步计算都能复算，每份交付的文字、表格和图表彼此一致。

要解决的问题：大模型已经能读几百页的年报、也能写代码算数，但在真实财报分析中，它们常常"算对了数，却写错了结论"：把期间写颠倒、把方向写反、把图画错，或者给出没有出处的解释。研究员拿到这样的结果，必须从头再核一遍。

我们的做法：把财报分析拆成三层可检查的工序。

1. **资料变成资产**：年报经脚本清洗入库，每个数字都记录主体、期间、口径、单位，以及原文页码和表格坐标。
2. **先有底稿，再下结论**：用户提出财报分析问题时，系统先由程序算好利润与现金桥、变动归因、异常信号，并找出对应的管理层原文，交给大模型的是一份成品底稿。
3. **交付前自动检查**：所有计算在断网沙箱中执行，正文、CSV、Excel 和图表引用同一组数值；交付前检查方向措辞、期间顺序、瀑布图连续性和估值说明是否完整。

目前的成果：

- 系统已完成三个公开版本迭代（v0.1 → v0.2.0 → v0.3.0）和 v3 分析层开发，提供可安装的便携发布包。
- 在三组对照的双盲评测中（同一模型、同一题目），v3 金融组在第二轮门槛中**有实质缺陷的回答降到 1/6 和 2/6**（两位评审分别评定），同期两个通用对照组为 3/6 到 4/6；**解释深度和异常识别评分在两位评审中都领先。**
- 正式评测（162 回合，含一家开发期间从未接触过的新公司）结果：【待填】。

二、痛点：一个具体的例子

伊利股份 2024 年报显示，合并净利润从 102.84 亿元降到 84.64 亿元，经营活动现金流却从 182.90 亿元增加到 217.40 亿元，多了约 34.5 亿元。为什么？

要回答这个问题，研究员需要翻到年报第 217–218 页的现金流量表补充资料，逐项核对折旧摊销、减值、投资收益、营运资金变动，再到管理层讨论里找原因（春节备货、经销商预收款），最后判断这种改善能否持续。答案散落在主表、附注和文字之间，而且每一步都有口径陷阱：合并还是母公司？归母还是整体？本期还是累计？

我们让通用大模型（同一个强模型、同样的资料）回答这类问题时，记录到的真实错误如下，全部来自盲评记录：

错误类型	真实实例
期间顺序颠倒	报告写"合并净利润由 8,463.7 降至 10,284.3（百万元）"，前后两期写反
关系方向写反	质保费用从销售费用重分类进营业成本后，毛利率与销售费用率**同向**下降 3.04 个百分点，报告却写"方向相反"
图表几何错误	现金桥瀑布图的负值柱被重复下移一次，桥在图上"断开"
序列错位	图中把归母净利润和经营现金流两个数值互换
单位失配	CSV 中的数值是百万元，表头却标为亿元，相差 100 倍

这些错误有一个共同点：**数算对了，写出来错了。**模型的计算往往没问题，问题出在从计算结果到文字、表格、图表的"最后一公里"。这正是本项目要攻克的地方。

三、产品与应用场景

3.1 产品形态

Finance Agent 是一个在本机运行的研究工作台：

- **项目与会话**：一家公司或一个研究主题为一个项目，项目内的多个会话共享资料，不同项目相互隔离。
- **附件流向**：每份年报、研报被如何处理、存到哪里、被哪次分析引用，一目了然。
- **资产看板**：已入库的财务事实、研报预测、观点和保存的模型集中展示，任何数字都可以一键跳回原文所在页。
- **研究成果**：每次分析交付 Markdown 报告、CSV 与 Excel 底稿、图表和可复算的 Python 脚本。

【截图位置：资产看板（财务事实与原文跳转）】

【截图位置：一次财报分析的交付结果（底稿、现金桥图、来源）】

3.2 目标用户

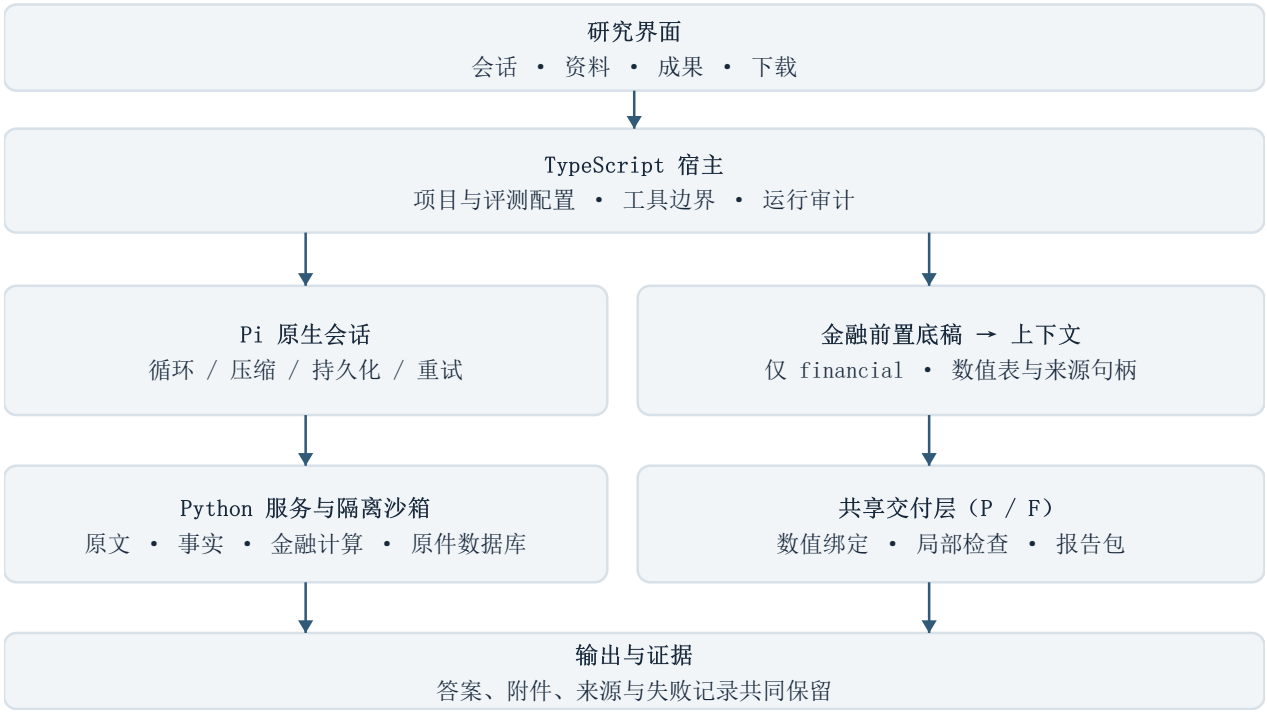
用户	典型任务	Finance Agent 提供的帮助
券商 / 买方研究员	年报季业绩点评、盈利质量判断	底稿先行，初稿附带完整来源和可复算脚本
企业财务与投资者关系人员	解释利润与现金流背离、会计口径调整影响	利润与现金桥、口径标记、管理层原文对齐
金融专业师生	财报阅读教学、案例复盘	每步计算可复算，典型错误可展示
进阶个人投资者	深度阅读单家公司	本机运行，原件与数据库不出本机

3.3 典型任务

- 业绩与现金流解释（利润为何下降、现金为何上升）
- 盈利质量与现金转化（非现金项目、营运资金、一次性损益）
- 会计政策变化的可比口径调整（如质保费用重分类对毛利率的影响）
- 异常信号识别与追问（季节性、备货、回款节奏、持续性判断）
- DCF 与相对估值的建立和局部更新

四、技术方案

4.1 系统架构



层次	技术	职责
界面	React 19、TypeScript、Vite	项目与会话、附件流向、资产看板、授权与用量展示
宿主	Express（TypeScript）+ Pi 智能体框架	任务生命周期、上下文压缩与重试恢复、工具白名单、请求识别与底稿注入
领域服务	Python 3.12，通过 MCP 协议接入	文档解析、脚本清洗、结构化事实、底稿流水线、金融模型、交付检查
存储	SQLite（含全文检索）+ 原件文件库	事实与证据分层保存，研究成果带版本
计算沙箱	Docker	断网、只读根文件系统、非 root、2 CPU / 2 GiB、单次 120 秒，执行模型编写的代码

推理引擎：系统以大语言模型为核心推理引擎，通过 OpenAI 兼容接口接入，模型可配置。历史工程验证使用国产模型 DeepSeek；本轮三组对照评测为保证条件一致，三组统一使用同一模型（gpt-6-luna）。

4.2 对照竞赛的五个必备模块

竞赛要求的模块	本项目的实现
任务编排	Pi 原生会话循环；宿主负责长任务检查点、断点续跑和中途消息
工具调用	MCP 领域工具：原版通用组 10 个、同数据通用组 13 个、金融组 32 个
提示指令	稳定前缀的系统提示，加四类金融技能（建模、模型复核更新、研报入库、产业链分析）
数据处理	PDF 与表格解析、脚本清洗入库、必经底稿流水线、统一数值交付
日志记录	审计日志（JSONL）、逐请求用量账本、产物清单与 SHA-256 哈希

竞赛要求"数据来源可核验、执行过程可追溯、运行结果可复现"，我们分别用以下三类材料回应：原文页码与表格坐标；完整的工具调用与沙箱执行记录；冻结版本、冻结数据与可重放的沙箱脚本。

4.3 关键技术

1. 脚本清洗，取代逐条转写。 模型不逐个抄写数字，而是编写映射脚本，由程序按原始单元格坐标取数，并检查主体、期间、单位和维度后事务式提交。转写错误和输出 token 同时下降。

2. 财务事实的数据模型。 每个事实记录主体、期间、口径、维度、单位、来源页码与坐标、处理版本。研报预测与公司披露分库保存，预测永远不会冒充披露。

3. 必经底稿流水线。 我们在早期评测中发现："有工具"不等于"会用工具"——专门的变动归因工具在财报题中两次都没有被模型调用。v3 改为由宿主在模型推理前直接运行底稿流水线，产出：关键指标、利润与现金桥、主要变动的归因与管理层原文（附页码）、已触发的异常信号、口径未齐标记和缺失项说明。模型拿到的是成品，完整表格以句柄方式按需读取。

4. 三层解释。 先引用披露事实（管理层原话与页码），再量化影响（能算的算出来，算不了的写明缺什么），最后给出标注为"推论"的判断。"公司定性披露了但没有量化"与"原文没有说明"分开表述。

5. 统一数值交付。 每个数值只换算一次展示单位，CSV、图表和正文由同一组结果生成，杜绝"正文对、图错十倍"这类问题。

6. 交付一致性检查。 交付前自动扫描正文、CSV 和 Excel 中的方向措辞与带符号数值是否矛盾、"由 X 降至 Y"的期间顺序是否正确、"方向相反/同向"的关系断言是否成立，并对瀑布图做几何连续性校验；发现问题时把具体位置返回给模型修正。

五、创新点

1. 程序先跑，模型拿成品。 大多数金融智能体把专业工具交给模型"自行选用"，我们的实测证明模型并不会稳定地用。Finance Agent 把底稿作为必经流程：专业步骤由宿主保证执行，模型专注于解释和判

断。金融规则放在领域层，不改动通用智能体的主循环。

2. 攻克"最后一公里"。 我们的错误分析表明，财报分析中的实质错误大多不在计算本身，而在计算结果写成文字、表格和图表的过程中。统一数值交付与交付一致性检查专门针对这一环节，并且每项检查都用真实失败样本验证命中、用历史正确交付验证误报（历史 70 份正确交付文本，误报 0）。

3. 用三组双盲评测回答两个问题。 我们不只和一个"被削弱的基线"比较，而是同时设置三组：

- **原版通用智能体**：通用提示与原始工具，代表"直接拿一个好模型来做"；
- **同数据通用组**：拿到与金融组完全相同的结构化资料和交付基建；
- **金融组**：在此之上增加金融底稿、金融工具和技能。

前两组之差回答"整套系统比直接用大模型好多少"，后两组之差回答"金融层本身贡献了多少"。评审由两位独立的匿名评审完成，第二位倒序评阅，分数封存后才揭盲；另有一家开发期间完全未接触的公司作为封存测试集。

4. 用负面结果驱动迭代。 每轮评测的缺陷都按来源归因：是金融层自己引入的、模型共性的，还是交付基建的。我们只修有证据的问题，门槛未达标时先诊断、不堆功能。下一节的迭代过程就是这一方法的实际体现。

六、评测与效果

6.1 评测设计

要素	设计
材料	开发集：卡罗特 2025 中报、伊利 2024 年报、海尔智家 2024 年报；封存测试集：一家新公司 2024 年报，开发期间未接触
题型	业绩与现金流解释、现金桥与盈利质量、会计重分类与可比口径，以及封存测试集上的三道新题
对照	原版通用智能体（10 工具）/ 同数据通用组（13 工具）/ 金融组（32 工具），同一模型
评分	读取、实质正确、业绩解释、口径调整、异常信号、交付质量六个维度（0–4 分），另计"实质缺陷"
评审	两位独立匿名评审，第二位倒序；附件匿名化后逐件核对；分数封存后揭盲
成本	逐请求记录输入、输出 token；资料准备成本与分析成本分开计算

结论判定规则在正式评测开跑前写定：一个对比结论必须在两位评审的评分中**各自独立成立**才算成立，同时两位评审的逐案一致率不低于 80%。

6.2 迭代闭环：从发现问题到定向修复

第一轮门槛（v3 初版，18 回合）：金融组的解释深度与异常识别首次领先（异常信号评分 4.00 对 2.25），但有实质缺陷的回答仍为 3/5，与通用组持平。

归因分析：我们逐条分析了两位评审确认的全部缺陷机制，发现：

- 大部分错误三组都有，属于模型共性：手写瀑布图负柱错位、方向措辞写反、期间顺序颠倒；
- 只有一类是金融层自己引入的：底稿把"报告期内已完成的并表"误标为"不证明本期发生"。

定向修复（v3.1）：只修有证据的问题，不加新功能——修正底稿的事项判定规则，新增瀑布图连续性检查，把方向检查扩展到 Excel、期间顺序和关系断言。

第二轮门槛（v3.1，18 回合）：

指标（评审一 / 评审二）	原版通用智能体	同数据通用组	金融组
有实质缺陷的回答	3/6、4/6	3/6、4/6	**1/6、2/6**
业绩解释评分	2.50、2.50	2.33、2.50	**3.17、2.83**
异常信号评分	2.50、3.00	2.50、3.00	**3.33、3.17**
方向类实质缺陷（条）	2、2	3、3	**0、0**
已知输入 token（6 回合合计）	235 万	382 万	291 万

两位评审各自独立评分，金融组在缺陷数量和分析深度上都达到了预设门槛。金融组的输入比同数据通用组少 24%，比原版通用智能体多 24%（原版不读取结构化底稿，分析更浅）；如果按"每个无缺陷回答"计算，金融组的投入低于原版通用智能体。

6.3 正式评测结果

【待填：正式评测 162 回合的两张主表——整套系统对原版通用智能体、金融层对同数据通用组，分开发集与封存测试集；质量、深度、成本三张图；可靠性指标】

6.4 历史工程验收

验收项	结果
完整财报入库（57 页中报）	50/50 张候选表有处理结论，612 条披露事实，独立原文金额抽样 34/34 一致
完整研报入库（38 页）	998 条研究数值、78 条观点原句全部可定位，抽样 15/15 一致
金融模型（FCFF DCF 等）	3 个模型、75/75 项独立复算通过
全流程模型费用	192 次请求，按 DeepSeek 计价估算 3.69–7.39 元人民币
软件回归	167 项 Node 与 405 项 Python 测试通过（v0.2.0 发布时）

七、对照评审标准

评审标准	我们的设计	证据
任务完成度	完整入库不截断；长任务断点续跑；局部问题降级交付而不整轮作废	第二轮门槛 18/18 完成，无人工补跑；【待填：正式评测完成率】
数据与计算准确性	原格坐标取数；十进制运算；统一数值交付	75/75 模型复算；34/34 原文抽样；金融组实质缺陷 1–2/6
分析逻辑严密性	必经底稿；三层解释；口径未齐标记进入答案约束	业绩解释评分 3.17 / 2.83，两位评审均领先
证据支撑充分性	事实到页码与坐标；管理层原文对齐；来源一键跳转	78/78 观点原句可定位；附件逐件核对
结果稳定性	每题多次重复；双遍独立评审；分歧全部公开	正式评测核心与封存测试集每题每组 6 次重复【待填：一致率】
方案创新性	必经底稿、"最后一公里"检查、三组双盲评测、负面结果驱动迭代	两轮门槛的完整迭代记录
实际应用价值	本机部署；成本按 token 计量可控；面向研究、财务、教学	便携发布包；逐请求用量账本

八、进度安排

阶段	时间	内容	状态
原型与冻结问答评测	2026 年 10 月初以前	财报解析、取数问答、证据定位、124 题冻结评测	已完成
v0.1 / v0.2.0 / v0.3.0	10 月 4–6 日	便携发布、资产看板、脚本清洗、统一数值交付、技术论文	已完成
v3 分析层与两轮门槛	10 月 8–9 日	必经底稿、深度解释、交付检查、定向修复	已完成
正式评测	10 月 9–13 日	162 回合三组双盲评测	进行中
初赛提交	10 月 18 日前	项目计划书、技术报告、介绍视频	进行中
决赛准备	10 月下旬至 11 月	上下文瘦身（降低输入成本）、更多行业复验、现场样例与答辩材料	计划中

决赛前的重点是**上下文瘦身**：把已被模型读取过的大块工具结果替换为摘要与可重读句柄，精简金融组的系统提示和工具说明，目标是在质量不下降的前提下，使金融组的输入不高于原版通用智能体。

九、推广与应用前景

- **开源本机版**：Windows 便携包，解压即用；用户使用自己的模型 API Key，按实际 token 付费，项目不托管任何用户数据。
- **教学版**：用公开财报样本和真实错误案例，展示"错误是怎样被发现的"，适合财报分析和金融科技课程。
- **机构私有部署**（后续）：将本地数据库升级为服务端数据库，增加组织权限、审计与配额；数据层与模型层分离，便于对接机构内部数据源和国产模型。

十、风险与应对

风险	现状	应对
模型的错误解释	底稿先行与交付检查已显著减少方向类错误，但口径归因等语义错误仍会出现	底稿补充现金流层级等结构化字段；扩大真实错误样本库，持续回归
成本	金融组输入低于同数据通用组，但高于原版通用智能体	决赛前完成上下文瘦身并按同一协议复测
评测的代表性	开发集三家公司、封存测试集一家公司，评审为模型评审	增加行业与公司样本；引入金融专业人员人工复核
评审一致性	两位模型评审在少数案例的严重程度上存在分歧	结论须两位评审各自成立；分歧全部公开；补充评分细则判例
数据安全	原件与数据库存本机，代码在断网沙箱执行	发给模型服务的仅为任务所需片段；支持切换为私有部署模型
第三方组件许可	已列出主要组件及许可证	发布前逐项核对，见 `THIRD_PARTY_NOTICES.md`

十一、团队与资源

角色	成员	主要职责
项目负责人 / 金融方法	【队伍】	需求、会计口径、结果解释
系统与数据工程	【队伍】	资料处理、宿主、底稿流水线、交付
评测与证据	【队伍】	题集、盲评、核验与成本核算
文档与演示	【队伍】	提交材料、现场演示与答辩
指导教师	【队伍】	方法与项目指导

资源：本机 Windows x64 与 Docker 沙箱；大语言模型 API（OpenAI 兼容接口）。**主要第三方组件**：Pi 智能体框架、MCP、React、Express、TypeScript、SQLite、PyMuPDF、pdfplumber、pandas、openpyxl、matplotlib、RapidOCR / ONNX Runtime、Docker。来源与许可证见 `THIRD_PARTY_NOTICES.md`。

附：证据索引（路径相对项目根目录）

内容	文件
竞赛通知	https://jw.beijing.gov.cn/gjc/tzgg_15688/202608/t20260827_4839055.html
系统设计与历史验收	`paper/v0.3.0/finance-agent-technical-paper.md`
v3 设计	`design/harness-v3-usable-depth-20261008.md`
评测方案与开跑前修订	`benchmark/blind-eval/V3_THREE_ARM_PLAN_20261008.md`、`benchmark/blind-eval/V3_PROTOCOL_REVISION_20261009.md`
第一轮门槛与归因	`data/evaluation/blind-eval-F203-gate-20261009/GATE_REPORT.md`、`design/f203-gate-diagnosis-20261009.md`
第二轮门槛	`data/evaluation/blind-eval-F21-gate-20261009/GATE_REPORT.md`
检查项的命中与误报验证	`docs/evidence/f21-20261009/README.md`
正式评测	【待填】